王振冉

合肥工业大学数学硕士
联系电话: 13965880069， **微信号**: Zhenran-Wang
邮箱: zhenran.w.1103@gmail.com, wzhenran1103@163.com



教育背景

北京航空航天大学，计算机学院，博士（人工智能方向） 2027.09 - 2031.09

- **导师**：黄斐然 **研究方向**：人工智能、多智能体、具身智能

合肥工业大学，数学，硕士 2022.08 - 2025.06

- **GPA**：3.8 / 4.0 **导师**：陈小锋教授
- **研究方向**：组合优化、图论与枚举问题 **主要成果**：两篇数学论文，一篇被**国际顶刊** **TAMS** 录用，一篇在 E-JC 在审

安徽财经大学，数学与应用数学，本科 2018.09 - 2022.07

- **核心课程**：数学分析、高等代数、概率论与数理统计、常微分方程、实变函数、Python 程序设计、数据结构与算法

代表论文 （均为一作或共同一作）

Embodied-SocialSim: A Device-Ready Agent Framework for Embodied Robots

Z. Wang†*, Z. Bian†, J. Li, Z. Qi* **[In Preparation]**

基于 Agnes Harness 搭建设备侧可部署的具身 Agent 主框架，将任务状态、工具审批、执行轨迹与恢复机制接入同一运行链路；以 MHS-MOS 风格接口连接设备状态、传感器观测与机器人行动，并接入视觉感知（如 YOLO）、状态估计、规划与执行等模块；在此基础上构造机器人、角色、关系与事件组成的模拟社会，作为研究具身 Agent 感知、决策、协作、冲突、信任与规范遵循的实验环境

Visual-RSI: Can Agents Turn Visual Evidence into Better Training Data?

Z. Wang†, Z. Li†, Z. Bian, F. Huang*, Z. Qi **[CVPR In Preparation]**

设计视觉失败诊断驱动的训练数据研究框架，覆盖图表、几何、流程图与网页界面；规划 7 个模型与 4 个研究 harness 的交叉比较及四类诊断反馈消融，已实现图表构造局部验证，模型效果尚待实证

SocietyBench: Forecasting Counterfactual Social-World Evolution

Z. Wang†*, Z. Bian†, J. Li, Z. Qi* **[AAAI 2027 Under Review]**

基于 EventRadar 引擎与 SocietyBench 框架，构建从社会事件数据采集到 LLM 预测能力评测的闭环
提出 Retrospective Evaluation 范式：以早期信息为输入、真实结局为 Ground Truth，实体匿名化杜绝背答案；概率校准与时间精度双轴评分，把「社会预测能力」落成可复现的客观度量：co-minder.github.io/Societybench

GroundBench: Multi-Resolution Polygon Grounding Exposes the Geometry Gap in Vision–Language Models

Z. Bian†*, **Z. Wang**†*, J. Li, Z. Qi* **[ICLR Under Review]**

提出 GroundBench：把 RefCOCO 系列同源的 1,500 组图文指代样本从边界框改造为五种顶点预算下的 exact-N 多边形，以固定分母框架分别审计填充区域 IoU 与合法多边形完成率
把定位得分拆解为目标选择与轮廓描摹两段：模型能选对物体、却描不准边界，语义歧义解决之后仍存在显著边界误差；精度随顶点预算非单调，N=32 前不升、N=64 反降：co-minder.github.io/Groundbench

WorldCup: Prospective, Leakage-Free Evaluation of Frontier LLMs on a Live Tournament

Z. Wang†*, Z. Bian†, J. Li, Z. Qi* **[arXiv]**

提出前瞻式无泄露评测范式：2026 世界杯 39 天内，6 个前沿模型于每场开赛前逐场作答，覆盖 104 场七市场预测卡、12 个小组头名与赛前夺冠盘，冻结存档 4,494 条已计分预测——提问时答案尚不存在，泄露免疫由构造保证而非事后过滤
覆盖 104 场 × 7 市场、12 组头名与赛前夺冠盘，冻结存档 4,494 条已计分预测；赛果预测平均 63.9%，与直接押博彩热门持平，模型间趋同度高于其正确率、多数投票无增益：co-minder.github.io/worldcup2026

Hurwitz-CC: Hurwitz Numbers with Completed Cycles and Gromov–Witten Theory Relative to at Most Three Points

X. Chen, **Z. Wang** **[TAMS Accepted]**

首次对任意类型完备圈的 Hurwitz 数进行研究，给出 $(1, m)$ 部三重 Hurwitz 数的显式计算公式与生成函数
首次提出钩形 Hurwitz 数概念，证明单部双重 Hurwitz 数相关结构的多项式性质：arXiv:2311.06316

Hurwitz-λ_g: Explicit Formulas and λ_g Conjecture for Double Hurwitz Numbers with Completed r-cycles

X. Chen, **Z. Wang** [**E-JC** Under Review]

首次给出带有完备 r 圈的单部双重 Hurwitz 数的显式公式
证明 λ_g 猜想类似物，并推导出弦方程和膨胀方程

注：† 共同第一作者，∗ 通讯作者。理论数学论文（**TAMS**、**E-JC**）作者按姓氏字母排序，无第一作者之分，默认同等贡献。**TAMS** = Trans. Amer. Math. Soc.（数学国际顶刊），**E-JC** = Electron. J. Combin.（组合数学国际知名期刊）

项目经历

RSI-Math ——数学推理模型的失败诊断与递归自改进数据框架 2026.08 - 至今

- **技术栈**：Python / PyTorch / SymPy / LLM API / Researcher Agent
- 以模型在代数、几何、组合与证明任务中的可验证错误为入口，拆解细粒度能力缺口，针对性生成题目、解答、反例与程序化验算数据，形成“诊断—干预—重训”闭环
- 从统一初始模型 M_0 启动多轮候选训练，保留生成、验证、筛选、训练与评测轨迹，用 hold-out、verifier 与 best-of-k 对照区分真实能力迁移和采样/选择波动
- 重点考察错误修复能否迁移到未见题型、不同难度与跨任务组合，并记录数据规模、训练轮次与验证成本，为递归改进的稳定性和可复现性提供依据

Embodied-SocialSim ——面向具身机器人的可部署 Agent 框架与社会仿真系统 2026.08 - 至今

- **技术栈**：Python / Agnes Harness / ROS2 / YOLO / MHS-MOS / LLM Agent / MiroFish
- 基于 Agnes Harness 搭建设备侧可部署的具身 Agent 主框架，将任务状态、工具审批、执行轨迹与恢复机制接入同一运行链路；以 MHS-MOS 风格接口连接设备状态、传感器观测与机器人行动
- 将视觉感知（如 YOLO）、状态估计、规划与执行等模块接入可替换的机器人系统骨架，并保留 ROS2 等设备侧接口；具体运动控制、互锁与急停由设备控制器负责
- 在框架之上构造机器人、角色、关系与事件组成的模拟社会，作为研究具身 Agent 感知、决策、协作、冲突、信任与规范遵循的实验环境，而非把项目主线限定为社会事件预测

EventRadar ——多平台社会事件数据采集与智能处理系统 2026.01 - 2026.07

- **技术栈**：Python / asyncio / aiohttp / Playwright / FastAPI / SQLite / LLM API / Claude Code Skills
- 端到端社会事件舆情系统——输入一句话研究课题，自动完成多平台数据采集、LLM 语义处理与跨源融合，输出结构化事件时间线，全程无需人工介入
- 基于 asyncio + aiohttp 异步并发架构覆盖 7 个社媒平台 + Web 新闻源，通过 Playwright 处理动态渲染页面，集成 SignSrv 签名服务、多账号 Cookie 池调度、代理轮换与断点续爬；自研 LLM 驱动的关键词生成 → 试爬验证 → 有效性审查闭环，从一句话研究课题自动收敛为 ≤ 15 个高质量关键词，全程零人工筛选
- 基于 FastAPI 构建处理服务，设计 LLM 六阶段语义流水线（摘要 → 清洗 → 语义去重 → 新进展提取 → 压缩 → 扩写），新闻/社媒双线 asyncio 并行后跨源合并，结果标注来源（新闻/社媒/双源印证），兼顾客观性与舆论温度
- 全流程拆分为 **20+ Claude Code Skills** 可编排微工作流，中间产物持久化至 SQLite 支持断点恢复与可视化检查；实测将 **10 万 + 社媒帖子 + 520 篇新闻**自动精炼为约 **30 条**结构化事件时间线，一键运行约 40 分钟完成

SocietyBench ——大语言模型社会事件预测能力评测基准 co-minder.github.io/Societybench 2026.02 - 2026.09

- **技术栈**：Python / asyncio / FastAPI / LLM API / Claude Code Skills
- 面向 AI 社会化场景，构建 LLM 社会事件预测能力的系统性评测基准——不考模型知道什么，考模型能否像社会学研究者一样，基于早期有限信息预判事件走势与公众反应
- 提出 Retrospective Evaluation（事后回溯）范式，用已发生事件的早期信息作为输入、真实结果作为 Ground Truth，配套实体匿名化防止模型” 作弊”；设计**双轴评测基准**——**概率校准**（加权 MAE 衡量模型对事件多种结局的概率预测准度）与**时间精度**（MAE 衡量事件发生时间的预测误差），两轴独立百分制评分，引入时间衰减权重与 temperature 稳定性控制保证可复现
- 基于 asyncio 实现 2 条评测线并行调度，通过 FastAPI 封装评测服务接口，Ground Truth 由 EventRadar 系统自动生成，全流程（匿名化 → 题库生成 → 多模型并行评测 → 成绩单输出）无需人工标注
- 约 **1 小时**出完整成绩单，对 **GPT-5.5**、**Gemini-3.5-Flash**、**Claude-Opus-4.8**、**DeepSeek-V4-Pro**、**Kimi-K2.5**、**Doubao-Seed-2.0-Pro** 6 个前沿模型完成 125 个预测点评测，单轴最大分差达 **21.4 分**，为自研社会预测引擎 MiroFish 的底层模型选型提供直接依据

GroundBench ——视觉语言模型多边形指代评测基准 co-minder.github.io/Groundbench 2026.04 - 2026.08

- **技术栈**：Python / PyTorch / Shapely / VLM API / RefCOCO / Claude Code Skills
- 针对 RefCOCO 系列边界框指代在前沿视觉语言模型上**已近饱和、拉不开差距**的问题，提出 GroundBench——将同源 1,500 组图文指代从边界框升级为五种顶点预算下的 exact-N 多边形指代，以固定分母框架分别审计填充区域 IoU 与合法多边形完成率
- 在饱和的框类指标上**重新拉开区分度**：最强配置框 IoU 达 **88.2**、直接输出多边形仅 **57.7**，且性能随顶点数非单调、最密预算下崩溃，暴露前沿模型在定位、边界构造、序列化与拓扑上的「输出几何鸿沟」
- 对 Doubao、Kimi、Qwen、Gemini 4 个前沿 VLM 及思考/模板消融完成评测，配套多项鲁棒性检查；框架**可扩展性强**，顶点预算、任务形态与接入模型均可持续扩充，为后续几何指代评测预留广阔空间

LLM · WorldCup ——大模型实时预测 · 世界杯实战 co-minder.github.io/worldcup2026 2026.04 - 2026.08

- **技术栈**：Python / FastAPI / LLM API / GitHub Pages / Claude Code Skills
- 前瞻式 LLM 预测擂台——6 个旗舰模型在统一赛前信息下预测 2026 世界杯，赛后按真实赛果计分排名、实时公开于 co-minder.github.io/worldcup2026；考验模型在有限赛前信息下的真实推理与预测能力

- 覆盖三类预测任务（单场 7 市场 / 12 组头名 / 全局走势），赛后按真实结果对各市场逐项判分、滚动更新积分榜；严格时序隔离、只喂开赛前快照，防赛果泄露，保证评测公平可复现
- 统一编排 6 家模型各异的联网搜索接口，并强制异构模型输出统一结构化预测；代码层硬门禁保证全量采集与防泄露，全流程 Python 脚本化、跨会话可复算
- 为 48 队各建结构化赛前档案——多源交叉核对，覆盖阵容、身价、主教练、天气与场地等多维度信息，并随赛程增量更新；raw / processed / reference 三层留存去重，前端按真实赛果实时计分、随每轮自动更新，中英双语公开

工作经历

江淮汽车，*数据开发工程师* 2025.07 - 2026.04

- **智能工单与客诉分析系统**：基于大模型 API 设计客诉处理 Agent，涵盖意图识别、文本分类、信息抽取与智能派单；FastAPI 构建后端服务，Redis 缓存对话状态支持多轮上下文，替代人工研判流程，效率提升约 **60%**，派单准确率达 **91%**
- 搭建多源业务数据 ETL 流水线（Hive + Doris），日均处理**数万条**业务数据，端到端延迟控制在 40 分钟内；MySQL + Redis 支撑工单流转与客诉记录的高并发读写，支撑全链路数据需求
- 搭建 Agent 质量评测流程，基于 Python 脚本自动化构建测试集与评估指标，通过 Prompt 策略迭代与 Few-shot 优化，将分类准确率从 **76%** 提升至 **93%**，召回率从 **68%** 提升至 **89%**

比亚迪股份有限公司，*数据算法实习生* 2023.05 - 2023.09

- **自动驾驶感知——纯视觉 BEV 3D 检测（数据方向）**：基于自研标注平台协作，完成多相机时间戳同步与帧对齐，过滤遮挡截断、标注偏移、时序异常等脏数据；基于 OpenCV 编写 3D → 2D 投影可视化脚本，结合 Open3D 做 BEV 下 3D 框空间校验，累计质检数据约 **8 万帧**
- 设计并实现面向 BEV 感知的多级数据增强策略，包括 GT-paste、BEVMix、GridMask、CutOut、随机翻转与 BEV 空间随机缩放等，配合算法团队迭代训练，在 nuScenes 验证集上模型 **mAP 提升约 5.2 个点**，**NDS 提升约 4.1 个点**
- 搭建从原始采集数据（公司自定义 protobuf 格式）到 nuScenes 标准训练格式的自动化流水线，涵盖解析、清洗、标定校验、ego-pose 对齐、格式转换全流程，数据处理效率提升约 **3 倍**

奖励荣誉

研究生学业奖学金二等奖 2023

全国大学生数学竞赛省二等奖 2020

学习奖学金二等奖 2019

全国高中数学奥林匹克竞赛省级二等奖 × 2 2016, 2017

技能

- **编程语言:** 精通 Python，熟悉常用数据结构与算法; 了解 C++、Matlab
- **AI 与大模型:** 具备 LLM Agent 应用开发经验，熟悉 Prompt Engineering、多模型 API 编排与 LLM-as-Judge 评测范式; 熟悉 PyTorch
- **数据与工程:** 熟悉 FastAPI 等 Web 框架; 熟悉 MySQL、Redis、SQLite; 熟悉 Python 异步编程与多平台数据采集（Playwright、代理轮换、账号池）; 了解消息队列基本原理; 具备模块化自动化流水线设计经验
- **工程实践:** 熟悉 Git 协作流程与代码规范，具备单元测试与日志监控意识; 熟悉 Linux 开发环境
- **工具与语言:** VSCode、Cursor、Claude Code; 通过英语六级，具备优秀的英文读写能力